Algoritma özeti

Veri (`01_data.R`)

Sütunlar pozisyonla değil isimle seçilir. Pozisyonla silinen bir zincirde her adım sonrakinin numarasını kaydırır. Sıra değişirse kod hata vermez, yanlış değişkeni atar.

Bu dosyada yalnızca anlamı belli olan kurallar vardır. Ortalama, medyan ve mod burada hesaplanmaz. O sayılar test satırını da içine alır. Veriden öğrenilen doldurma, modelin içinde ve yalnızca eğitim katmanında yapılır.

Karar ağacı (`02_decision_tree.R`)

Akış aynı tutuldu. Veri %75 / %25 bölünür. Verim üç sınıfa ayrılır: A yüksek, B orta, C düşük. `minsplit` ve `cp` ızgarasında 5-fold çapraz doğrulama ile ikili seçilir. Seçilen model testte bir kez ölçülür. Çıktı karışıklık matrisi, ağaç grafiği ve değişken önemidir.

Dört düzeltme var.

Çapraz doğrulama fold indeksini gerçekten kullanır ve tabakalı olarak birkaç kez tekrarlanır. Eski döngüde indeks sabitti. Beş fold da birinci fold'u ölçüyordu.

Sınıf sınırları her bölmede eğitim verisinin tertilinden hesaplanır. Eski kodda 8.1 ve 138.1 yazılıydı. Bu sayılar bölmeye bağlıdır. 138.11 verimli satır, 138.1 eşiğinde yanlış sınıfa düşüyordu.

Tanımlayıcılar isimle seçilir.

Izgara, makalede yazılan aralıktır: minsplit 5'ten 30'a, cp 0.01'den 0.1'e. cp'nin altı da 0.002'ye kadar taranır. 0.01 alt sınırı keyfidir ve seçilen değer sık sık bu sınırın altında kalır.

Random forest (`03_random_forest.R`)

Kütüphane makaledekiyle aynı: `randomForest`. Bölme yine %75 / %25. Ağaç sayısı 500. Dört fark var.

Eksik değer yalnızca eğitim katmanından doldurulur. Medyan, her çapraz doğrulama katmanında ve son modelde sadece eğitim satırlarından alınır. Bütün tablodan alınan ortalama, test satırının kendi doldurma değerine katkı yapmasına yol açar.

`mtry` tek başına taranmaz. Düğüm büyüklüğü (`nodesize`) ile birlikte taranır. 26–27 tanımlayıcı ve 102–142 satırlık bir veride düğüm büyüklüğü en az `mtry` kadar belirleyicidir.

500 ağaç ayrıca OOB hata eğrisiyle kontrol edilir.

Değişken önemi iki ölçüyle verilir. Saflık artışı (`IncNodePurity`) çok seviyeli kategorik değişkenlere yanlıdır. Permütasyon önemi (`%IncMSE`) bu yanlılığı taşımaz.